EQUIPO 1

ESTADÍSTICA DE PALABRAS I

Enríquez Ramírez Oneida
Hernández Gómez Carolina
Ramírez Hernández Luz Ignacio

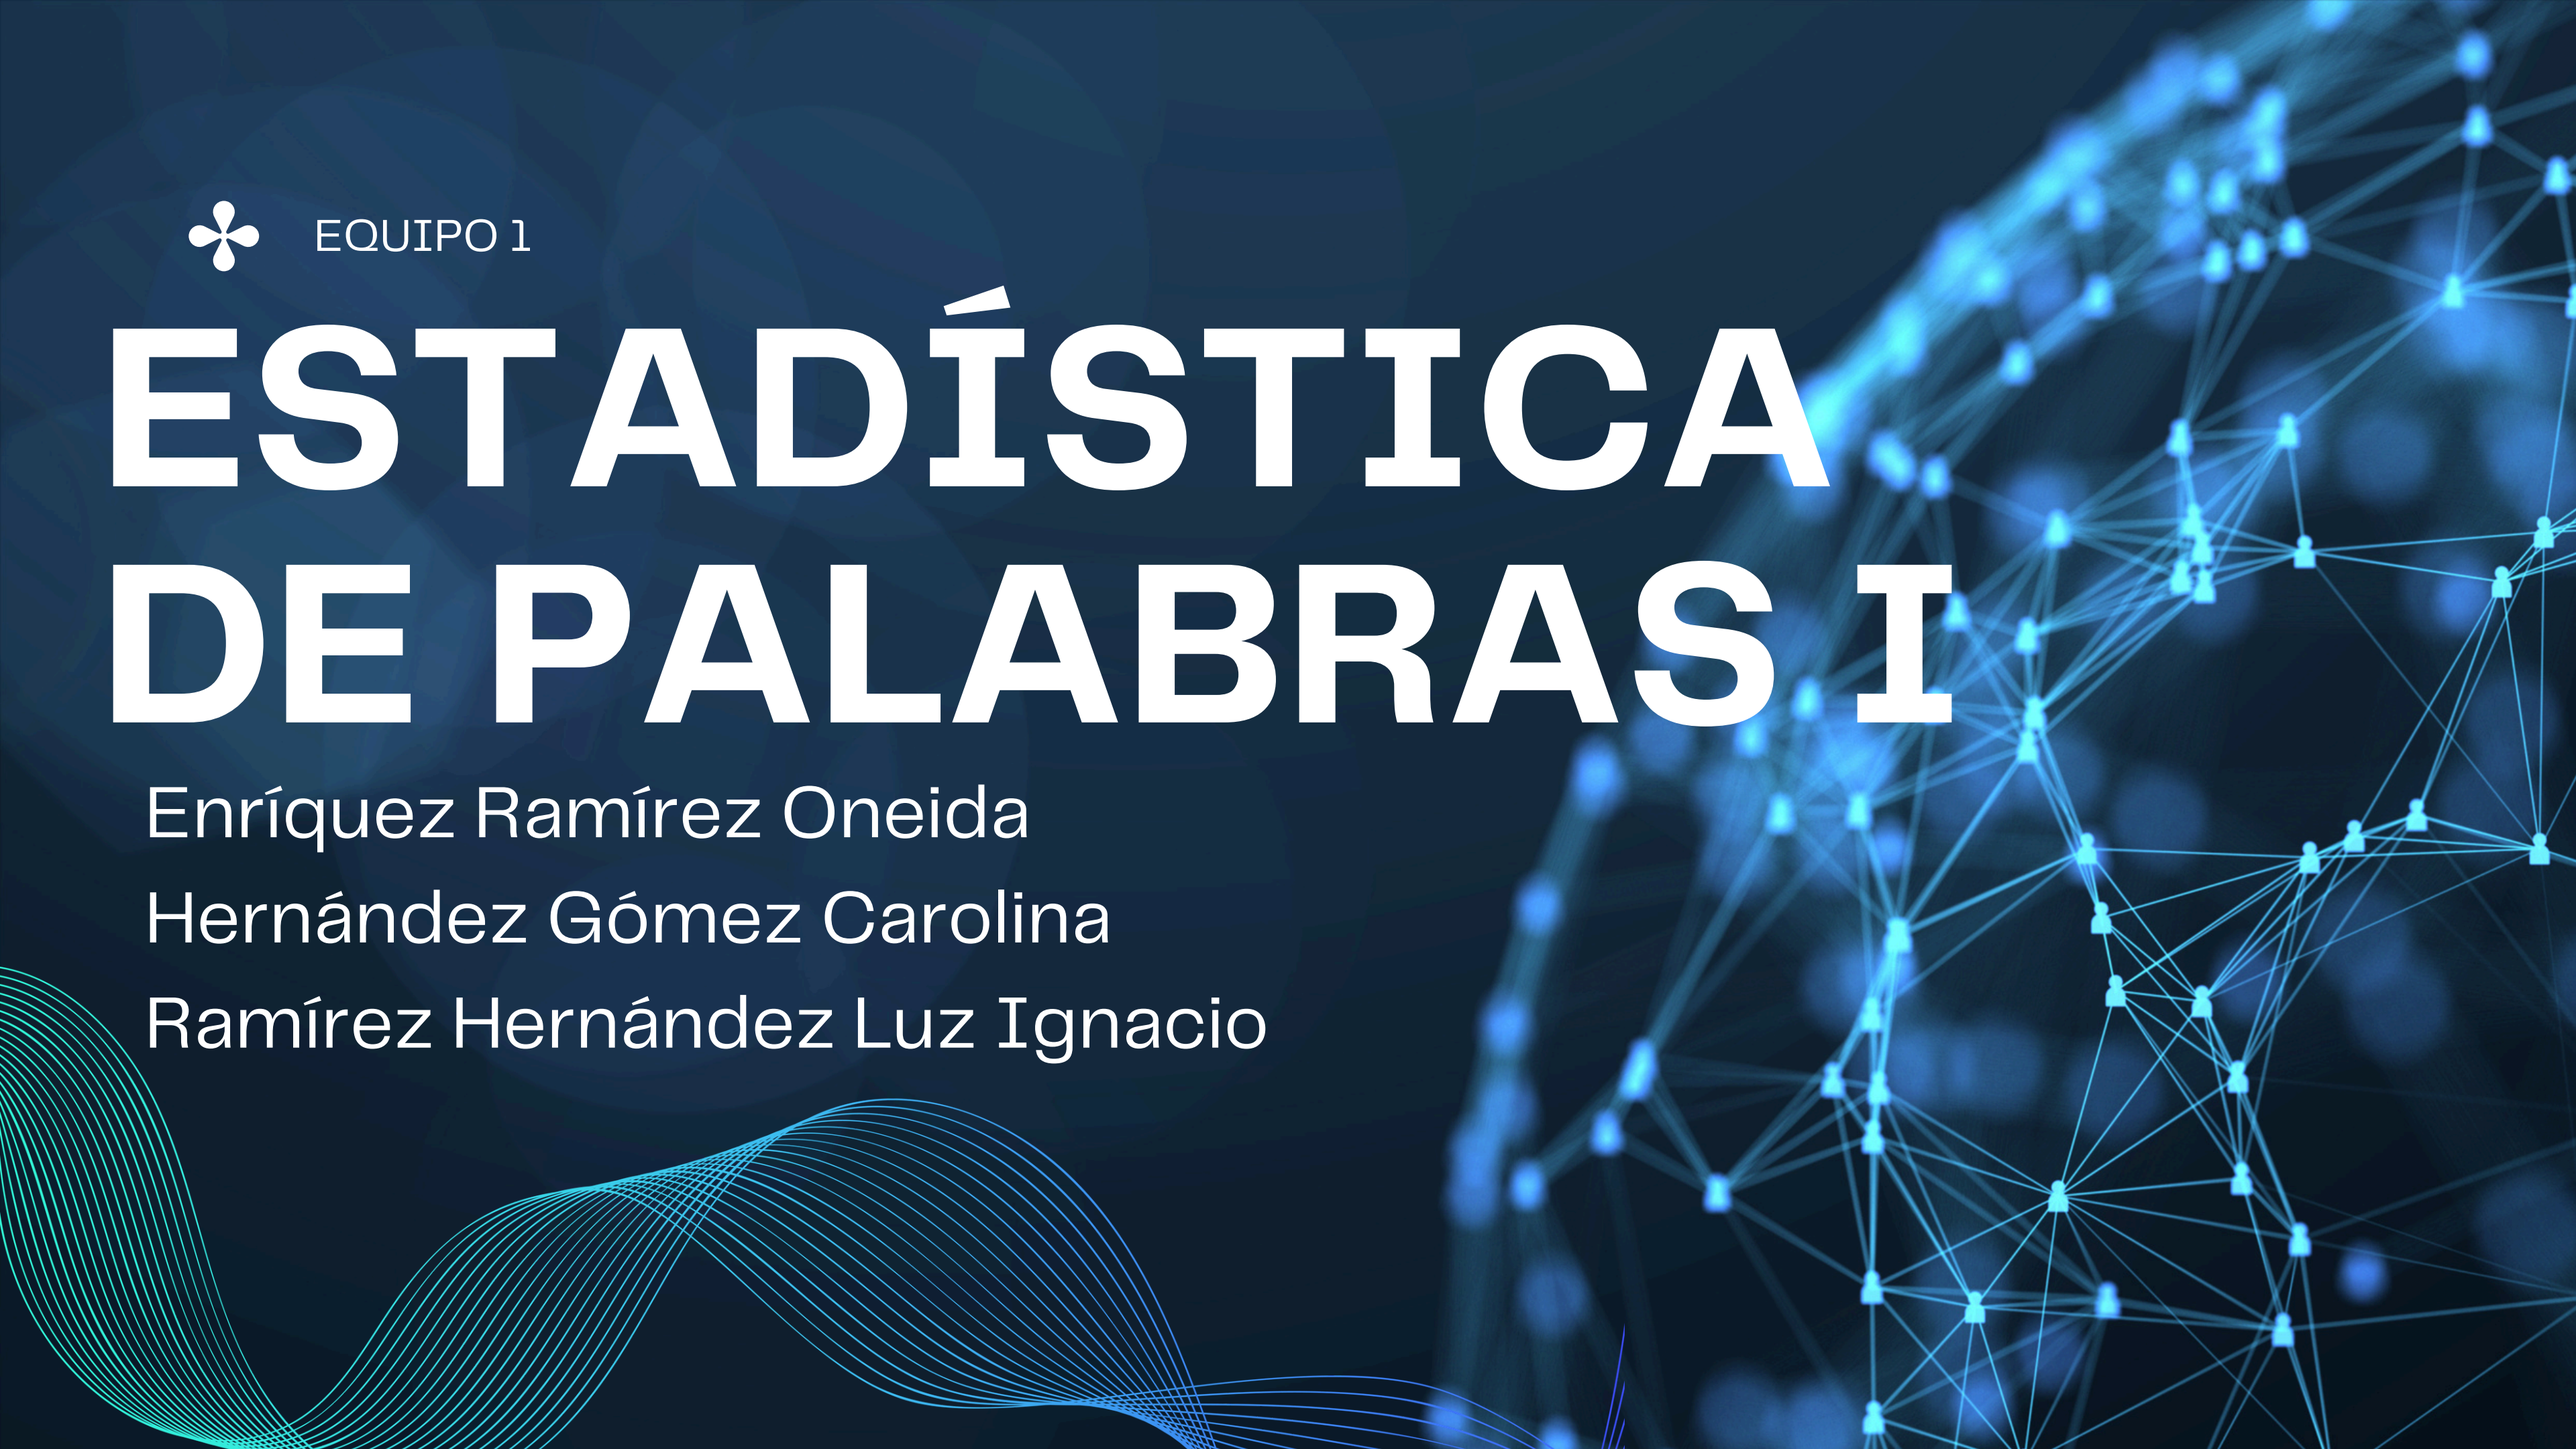

¿Qué es la estadística de palabras?

Es la disciplina que utiliza métodos matemáticos y estadísticos para analizar el lenguaje escrito o hablado. En lugar de estudiar el idioma únicamente desde sus reglas gramaticales, mide y modela la frecuencia, distribución y relación entre las palabras dentro de un texto o corpus.

Conceptos fundamentales

- Frecuencia de palabras: Cuenta cuántas veces aparece cada término. Revela los temas principales de un documento, aunque las palabras más comunes suelen ser palabras de función (artículos, preposiciones) llamadas stop words.

- Ley de Zipf: Una ley empírica central en la estadística del lenguaje que establece que la frecuencia de una palabra es inversamente proporcional a su posición (rank) en la lista de frecuencias. La palabra más común aparece aproximadamente el doble de veces que la segunda, el triple que la tercera, y así sucesivamente.

- Diversidad léxica (TTR – Type-Token Ratio): La relación entre el número de palabras únicas (types) y el número total de palabras (tokens). Sirve para medir la riqueza o variedad del vocabulario de un autor o texto.

Planteamiento de Ejemplo

Ejemplo – WordMean y WordMedian

Supongamos que tenemos cinco palabras con diferentes longitudes y queremos conocer el promedio y la mediana de la cantidad de letras que contienen.

Palabra	Número de letras
Sol	3
Casa	4
Libro	5
Escuela	7
Universidad	11

WordMean (promedio)

Suma la cantidad de letras de todas las palabras y divide el resultado entre el número total de palabras.

(3 + 4 + 5 + 7 + 11) ÷ 5 = 6 letras

WordMedian (mediana)

Ordena las longitudes de menor a mayor e identifica el valor central.

3, 4, 5, 7, 11

Resultado: 5 letras

WordMean obtiene un promedio de 6 letras, mientras que WordMedian identifica una mediana de 5 letras, lo que permite observar cómo ambos programas analizan la longitud de las palabras de manera diferente.

Wordmean

¿Qué es?

El término Word Mean (o la media de palabras / longitud media) se refiere principalmente a la Longitud Media de Palabra (Mean Word Length), un indicador métrico clave en estadística lingüística, estilometría y Procesamiento del Lenguaje Natural (PLN).
Mide el promedio de caracteres o sílabas que compone las palabras de un texto o cuerpo de datos dado.

¿Cómo se calcula?
La fórmula matemática es:

$$\text{Longitud Media de Palabra} = \frac{\text{Número total de caracteres (o sílabas)}}{\text{Número total de palabras (tokens)}}$$

EJEMPLO:

```
The median is: 5
hadoop@hadoop:/opt/hadoop/share/hadoop/mapreduce$ ls /tmp/equipo1/salida_med
ian
_SUCCESS  part-r-00000
hadoop@hadoop:/opt/hadoop/share/hadoop/mapreduce$ cat /tmp/equipo1/salida_me
dian/part-r-00000
3       1
4       1
5       1
7       1
11      1
```

Wordmedian

¿Qué es?

La Mediana de Longitud de Palabra (Word Median) es el valor central que divide la distribución de las longitudes de las palabras de un texto exactamente por la mitad: el 50% de las palabras son más cortas (o iguales) y el otro 50% son más largas.
A diferencia de la media (Word Mean), la mediana es una medida de tendencia central robusta, lo que significa que no se ve distorsionada por valores extremos o atípicos (como palabras excepcionalmente largas o neologismos técnicos).

¿Cómo se calcula?

1. Se toma el texto y se calcula el número de caracteres (o sílabas) de cada palabra.
2. Se ordenan las longitudes de menor a mayor.
3. Se selecciona el valor ubicado justo en el centro:
   - Si la cantidad total de palabras es impar, es el dato del centro.
   - Si es par, es el promedio de los dos datos centrales.

EJEMPLO:

```
The mean is: 6.0
hadoop@hadoop:/opt/hadoop/share/hadoop/mapreduce$ ls /tmp/equipo1/salida_mea
n
_SUCCESS  part-r-00000
hadoop@hadoop:/opt/hadoop/share/hadoop/mapreduce$ cat /tmp/equipo1/salida_me
an/part-r-00000
count   5
length  30
```

Criterio	Word Mean (Media de palabra)	Word Median (Mediana de palabra)
Definición	Promedio aritmético de la longitud de las palabras.	El valor central que divide la lista ordenada de longitudes al 50%.
Sensibilidad a palabras extremas	Alta. Una sola palabra muy larga (ej. electroencefalografista) aumenta mucho el resultado.	**Nula/Baja.** No le afectan las palabras extremadamente largas o cortas.
Representación del lenguaje	Refleja el peso total del texto, pero puede dar una falsa imagen del vocabulario cotidiano.	Representa mejor la "palabra típica" que un lector encuentra realmente.
Forma de cálculo	Suma de todos los caracteres dividida por el total de palabras.	Ordenar las longitudes de menor a mayor y tomar la posición central.
Uso principal	Fórmulas clásicas de legibilidad (Flesch-Kincaid, Gunning Fog) y modelos matemáticos globales.	Análisis lingüístico robusto, comparación de corpus con sesgos o textos no estructurados.

Diagrama de Map y Reduce

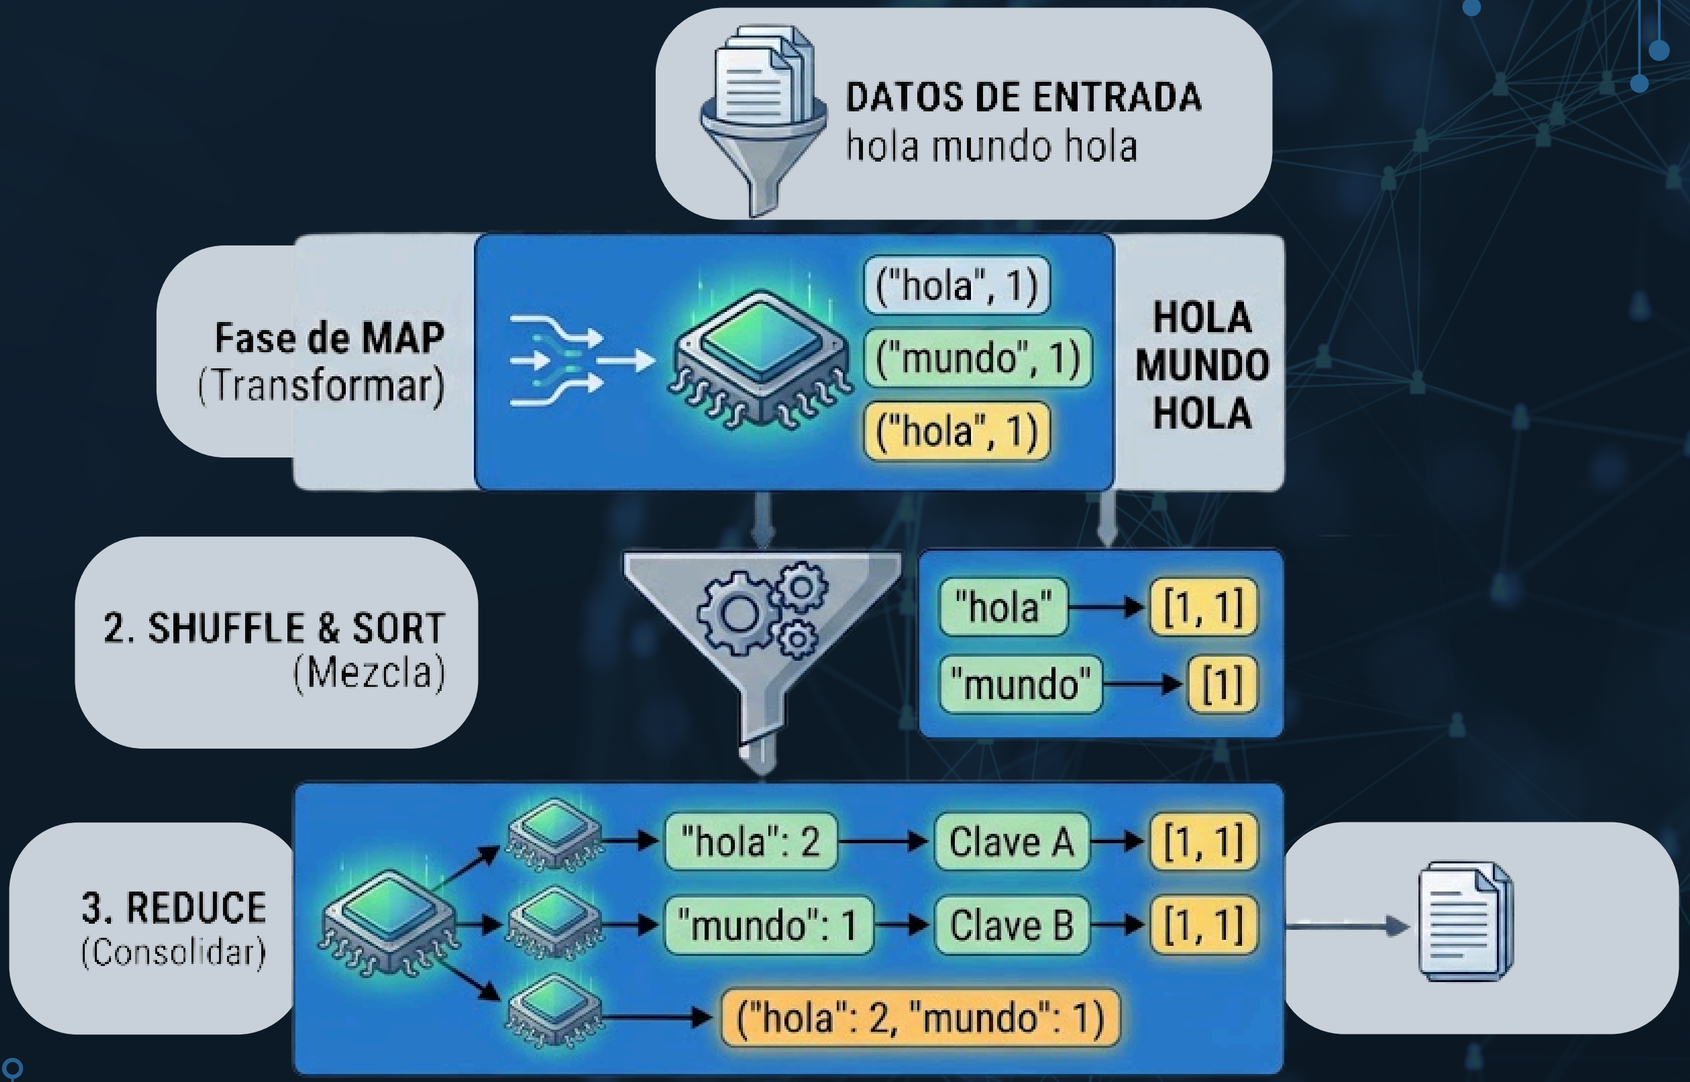

Caso Real de Aplicación

- Las empresas pueden utilizar WordMean y WordMedian para revisar grandes cantidades de comentarios sobre sus productos o servicios, permitiéndoles conocer mejor el tipo de vocabulario que utilizan sus clientes y obtener información sobre su manera de expresarse.

- En las redes sociales, estos programas pueden ayudar a analizar las palabras utilizadas en publicaciones y comentarios, identificando si el vocabulario suele ser sencillo o más elaborado, lo que puede servir para crear contenido más claro y fácil de entender.

Ejemplo

Demostración – WordMean y WordMedian

Para demostrar el funcionamiento de ambos programas, se analizó un texto basado en una noticia sobre la inversión en centros de datos de KIO Data Centers en México. El texto aborda el crecimiento de la infraestructura digital, el almacenamiento en la nube y la demanda de inteligencia artificial.

Resultados obtenidos en Hadoop:

Dato	Resultado
Palabras analizadas	75
Total de caracteres	413
WordMean (promedio)	5.51
WordMedian (mediana)	5

WordMean obtuvo un promedio de 5.51 caracteres por palabra, mientras que WordMedian identificó una longitud central de 5 caracteres. Esto permite observar cómo ambos programas analizan el mismo texto y generan resultados diferentes.

```
The median is: 5
hadoop@hadoop:/opt/hadoop/share/hadoop/mapreduce$ cat /tmp/equipo1/
salida_noticia_median/part-r-00000
1       4
2       19
3       8
4       6
5       3
6       4
7       10
8       4
9       9
10      1
11      2
12      1
13      1
14      1
15      2
```

```
The mean is: 5.506666666666667
hadoop@hadoop:/opt/hadoop/share/hadoop/mapreduce$ cat /tmp/equipo1/
salida_noticia_mean/part-r-00000
count   75
length  413
```

Ejercicio

Análisis de palabras sobre ciberseguridad

Objetivo: Calcular el promedio y la mediana de la longitud de las palabras utilizando los programas WordMean y WordMedian de Hadoop.

Texto de entrada:
La seguridad digital ayuda a proteger los datos personales
Usar claves seguras evita riesgos en internet
Los usuarios deben cuidar su informacion

Actividades:
1. Crear un archivo de texto con el contenido proporcionado.
2. Ejecutar WordMean y WordMedian utilizando Hadoop.
3. Consultar los resultados obtenidos.
4. Identificar cuántas palabras se analizaron y explicar la diferencia entre el promedio y la mediana.

Resultados

Al ejecutar ambos programas con el texto de ciberseguridad, se obtuvieron los siguientes resultados:

Dato	Resultado
Palabras analizadas	22
Total de caracteres	124
WordMean (promedio)	5.64
WordMedian (Hadoop)	5
Mediana estadística convencional	5.5

```
The mean is: 5.636363636363637
hadoop@hadoop:/opt/hadoop/share/hadoop/mapreduce$ cat /tmp/equipo1/
ejercicio/salida_mean/part-r-00000
count   22
length  124
```

```
The median is: 5
hadoop@hadoop:/opt/hadoop/share/hadoop/mapreduce$ cat /tmp/equipo1/
ejercicio/salida_median/part-r-00000
1       1
2       3
3       2
4       1
5       4
6       2
7       3
8       3
9       1
10      1
11      1
```

WordMean calculó un promedio de 5.64 caracteres por palabra, mientras que WordMedian mostró una mediana de 5. Como el texto contiene 22 palabras, al calcular manualmente la mediana se consideran las dos posiciones centrales, cuyos valores son 5 y 6, obteniendo 5.5.

YOU